

Laboratorio di ingegneria informatica - Aprile 2026 - Web Extraction Engine

Daniele Compagnoni (2114420)

compagnoni.2114420@studenti.uniroma1.it

Michele Pio Forlani (2115153)

forlani.2115153@studenti.uniroma1.it

Salvatore Iavarone (2056502)

iavarone.2056502@studenti.uniroma1.it

1 Obiettivo del progetto

L'obiettivo del progetto è lo sviluppo di un "Web Extraction Engine" a microservizi basato su container Docker. Il sistema sfrutta il browser automation per estrarre in formato Markdown, pulire dagli artefatti DOM e valutare algoritmicamente grandi formati documentali. L'intento finale è la raffinazione di dataset *Gold Standard* di elevata purezza, indispensabili per l'addestramento e il fine-tuning di modelli logico-generativi (RAG, LLMs).

2 Organizzazione del codice

L'architettura applica un rigoroso isolamento software e il principio di Single Responsibility (SRP) per ogni compartimento del sistema:

- **Modulo /backend:** Servizio FastAPI (porta 8003). Scopo: orchestrare la business logic automatizzando lo scraper headless (Crawl4AI/Playwright), applicare le cleaning pipeline basate su RegEx e iniezione JS, ed elaborare l'architettura matematica per la valutazione delle metriche NLP.
- **Modulo /backend/src/parsers:** Repository d'astrazione sito-specifica. Scopo: isolare tramite pattern polimorfici le regole di parsing di ogni dominio processato (wikipedia_parser.py, nobel_parser.py, governo_parser.py, romatoday_parser.py).
- **Modulo /frontend:** Dashboard reattiva Tailwind/Jinja2 (porta 8004). Scopo: restare disaccoppiata e semplice per limitarsi al puro rendering affiancato dei documenti, all'esposizione logica dei risultati e all'export del codice pulito in .md grezzo.
- **Modulo /gs_data:** Configurato unicamente in modalità Read. Custodisce le *golden refe-*

rence JSON per le comparazioni formali in locale in totale sicurezza.

3 Metriche di Valutazione e Risultati

Fondamenti Teorici L'architettura del sistema affida la validazione del Markdown generato a un pool di tre macro-rami di analisi matematica (per un totale di 8 metriche), confrontando gli estratti con le referenze *Gold Standard*. Il calcolo operativo rigetta logiche stocastiche per abbracciare definizioni algoritmiche esatte:

- **Core Token NLP (F1-Score, Precision, Recall):** L'analisi quantifica le intersezioni tra i set di word-level token predetti (P) e reali (R). La *Precision* misura l'accuratezza positiva ($\frac{|P \cap R|}{|P|}$), la *Recall* valuta la copertura dei dati attesi ($\frac{|P \cap R|}{|R|}$), e l'*F1-Score* definisce il loro compromesso armonico ($2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$).
- **Similarità Complessa (Jaccard, Rouge-L):** Per misurare la coesione sintattico-lessicale si elaborano insiemi di n -gram (tipicamente 3-gram). L'Indice di Jaccard modella tale vicinanza matematica calcolando il quoziente tra intersezione e unione ($J(A, B) = \frac{|A \cap B|}{|A \cup B|}$). Parallelamente, *Rouge-L* stima la Longest Common Subsequence (LCS), penalizzando severamente alterazioni nell'ordine frasale profondo.
- **Error Cost & Leakage:** La *Word Error Rate* (WER, calcolata come $\frac{S+D+I}{N}$) e la *Character Error Rate* (CER) derivano direttamente dalla distanza di Levenshtein, definendo il costo unificato in operazioni (Sostituzioni, Delezioni, Inserimenti) impiegate per riallineare l'estratto alla norma. In ultimo, il *Tag Leakage* quantifica cruscottamente lo *spillage* residuo calcolando l'esatta percentuale di sporcizia DOM scampata ai filtri.

Analisi dei Risultati L'effettiva acquisizione dei referti avviene all'interno del runtime isolato di FastAPI/Docker, che emette un report vettorializzato per ogni ciclo. Le evidenze dimostrano che le piattaforme più strutturate e ricche di semantica formale (Wikipedia, Governo) sfiorano un grado di fedeltà quasi assoluto. Di contro, portali intrinsecamente ricchi di garbage dinamico (RomaToday) innalzano comprensibilmente la Word Error Rate, criticità tuttavia mitigata con successo grazie all'utilizzo del parsing asincrono su Playwright e alla pipeline di cleaning dedicata. Questa metodologia produce evidenze matematiche provabili sull'efficacia dell'engine nel neutralizzare il rumore DOM prima dell'estrazione.

4 Ottimizzazione e Parallelismo

Per massimizzare il throughput del sistema, è stata implementata una strategia di esecuzione parallela dei task di estrazione e valutazione. Sfruttando la natura asincrona di FastAPI e le capacità multi-tab di Playwright, il motore processa simultaneamente molteplici URL, riducendo drasticamente i tempi di attesa complessivi. Questa scelta tecnica non solo ottimizza l'uso delle risorse computazionali del container, ma permette una scalabilità orizzontale efficiente durante la generazione di dataset Gold Standard su larga scala.

Esito dei Benchmark I test conclusivi eseguiti sull'endpoint di valutazione (/full_gs_eval) confermano empiricamente la solidità dell'architettura: il sistema ha superato con successo la totalità dei test previsti (26 su 26), registrando uno score medio perfetto pari a 1.00. Entrando nel dettaglio dell'F1-Score, i domini istituzionali ed enciclopedici hanno prodotto risultati ampiamente superiori alla soglia ottimale di 0.95, con `nobelprize.org` a 0.998, `governo.it` a 0.996 ed `en.wikipedia.org` a 0.979. Come anticipato teoricamente, il dominio `romatoday.it` ha presentato una sfida maggiore, ma ha comunque raggiunto un validissimo F1-Score di 0.869, collocandosi oltre la soglia definita "buona" (0.85) e garantendo un'estrazione affidabile nonostante l'elevata densità di contenuti non strutturati.